단계적 학습을 활용한 AI 생성 이미지 탐지 모델

CNN 및 ResNet 기반 AI vs Real Image Detection

고영훈 C289002
김건우 C289003
홍익대학교 소프트웨어융합학과



"AI 생성 이미지 시대, 탐지 모델은 얼마나 일반화될 수 있는가?"

왜 AI 이미지 탐지가 필요한가?

문제 배경

- 생성형 AI 기술의 발전으로 AI 이미지 급증
- 딥페이크, 허위 정보, 저작권 문제 발생
- 탐지 모델의 중요성 증가

기존 접근법의 한계

- 특정 데이터셋에 과적합
- 새로운 생성 모델에 취약
- 실제 환경에서 일반화 성능 부족

실제 이미지 → AI 생성 이미지 → 탐지 모델 → 성능 저하

"훈련 데이터가 바뀌면 성능이 급격히 감소한다."



AI 이미지 급증

DALL-E, Midjourney, Stable Diffusion
등 생성 모델 폭발적 증가



사회적 위협

딥페이크 악용, 허위 정보 유포
저작권 침해 문제 심화



탐지 한계

학습 데이터 외 환경에서
성능 급격히 하락

데이터셋 순서 결정 방법

난이도와 특성에 따라 단계적으로 학습 순서를 설계

Phase 1

🔬

CIFAKE

저해상도 기반
기초 특징 학습

Step 1

→

Phase 3

🖼️

AI vs Real Images Dataset

일반 이미지 기반
초기 일반화

Step 2

→

Phase 4

🎨

AI vs Human Generated Dataset

SDXL 기반
고품질 이미지

Step 3

→

Phase 5

👤

Real vs AI Generated Faces Dataset

고난도 얼굴
정밀 탐지

Step 4

난이도 순서: 저해상도 → 일반 이미지 → 고품질 → 고난도 얼굴

데이터셋 순서 결정 방법

난이도와 특성에 따라 단계적으로 학습 순서를 설계



Phase 1

CIFAKE

32 x 32
120,000 개
.jpg



Phase 3

AI vs Real Images

512 x 512
995 개
.jpg / .png



Phase 4

AI vs Human Generated

768 x 512
85,500 개
.jpg



Phase 5

Real vs AI Faces

512 x 512
242,000 개
.jpg

데이터셋 구조 확인

```
1_CIFAKE
├── train
│   ├── REAL (50,000)
│   └── FAKE (50,000)
└── test
    ├── REAL (10,000)
    └── FAKE (10,000)
```

```
3_AI_vs_Real
├── Ai_generated_dataset
│   ├── city (50)
│   ├── animals (50)
│   ├── nature (50)
│   ├── people (50)
│   └── food (50)
└── real_dataset
    ├── city (150)
    ├── animals (148)
    ├── nature (150)
    ├── people (147)
    └── food (150)
```

데이터셋 구조 확인

```
4_AI_vs_Human
├── train_data
│   └── 79,950 images
└── test_data_v2
    └── 5,540 images
```

```
5_Real_vs_AI_Faces
├── data_source
│   ├── ffhq (70,000)
│   └── fake
│       ├── stable_diffusion (1,031)
│       ├── faceswap (9,429)
│       ├── thispersondoesnotexist (20,499)
│       └── sfhq
│           ├── pt1 (5,000)
│           ├── pt2 (5,000)
│           ├── pt3 (5,000)
│           └── pt4 (5,000)
└── dataset
    ├── train
    │   ├── 0 (42,000)
    │   └── 1 (30,574)
    ├── validate
    │   ├── 0 (14,000)
    │   └── 1 (10,190)
    └── test
        ├── 0 (14,000)
        └── 1 (10,190)
```

데이터셋 전처리

```
ai  real

================================================
📁 TRAIN
real: 41637
ai: 48000
TOTAL: 89637

================================================
📁 VAL
real: 11618
ai: 12000
TOTAL: 23618
```

```
train  val

================================================
📁 TRAIN
real: 596
ai: 50
TOTAL: 646

================================================
📁 VAL
real: 149
ai: 31
TOTAL: 180
```

```
 ========================================
 Processing: /content/4_AI_vs_Human
 ========================================
 REAL: 39975
 AI: 39975
 real: train=31980, val=7995
```

```
train  val

================================================
📁 TRAIN
real: 56000
ai: 40767
TOTAL: 96767

================================================
📁 VAL
real: 14000
ai: 10192
TOTAL: 24192
```

실험

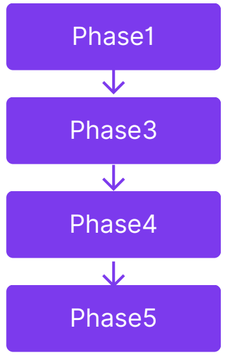
비교 대상 ① 개별 학습 모델



각 데이터셋만 독립적으로 학습

VS

비교 대상 ② 누적 학습 모델



이전 가중치를 유지한 채 순차적으로 학습

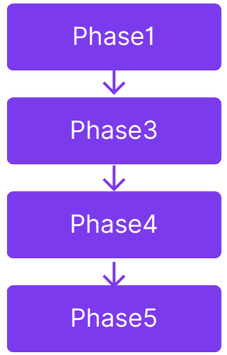
비교 대상 ① 개별 학습 모델



각 데이터셋만 독립적으로 학습

VS

비교 대상 ② 누적 학습 모델

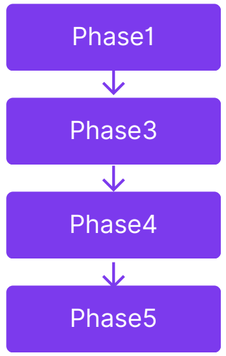


이전 가중치를 유지한 채 순차적으로 학습

Test DataSet : SynthBuster

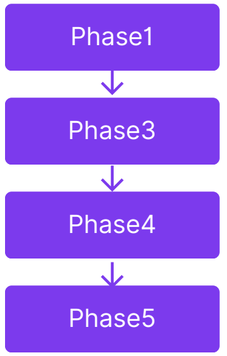
- 학습에 전혀 사용되지 않은 데이터
- 최신 AI 생성 이미지 포함
- 현실적인 일반화 성능 평가 가능
- 현재 가장 어려운 AI 이미지 탐지 벤치마크 중 하나

CNN 누적 학습 모델



VS

ResNet18 누적 학습 모델



설계(CNN)

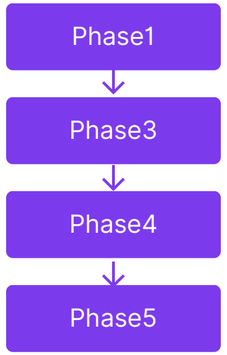
비교 대상 ① 개별 학습 모델



각 데이터셋만 독립적으로 학습

VS

비교 대상 ② 누적 학습 모델



이전 가중치를 유지한 채 순차적으로 학습

Test DataSet : SynthBuster

- 학습에 전혀 사용되지 않은 데이터
- 최신 AI 생성 이미지 포함
- 현실적인 일반화 성능 평가 가능
- 현재 가장 어려운 AI 이미지 탐지 벤치마크 중 하나

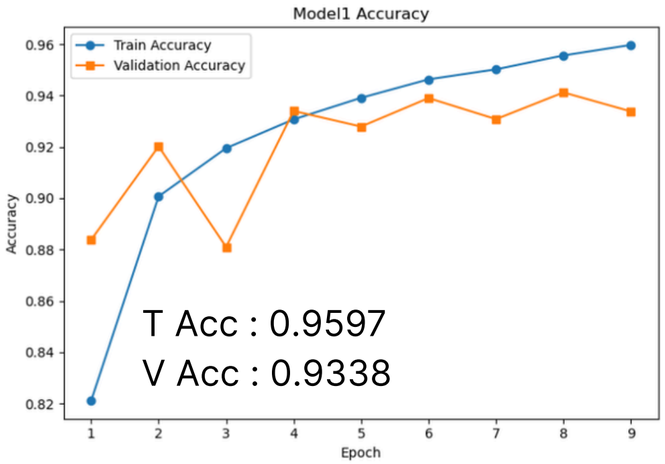
개별 학습 모델 VS 누적 학습 모델 → SynthBuster 평가

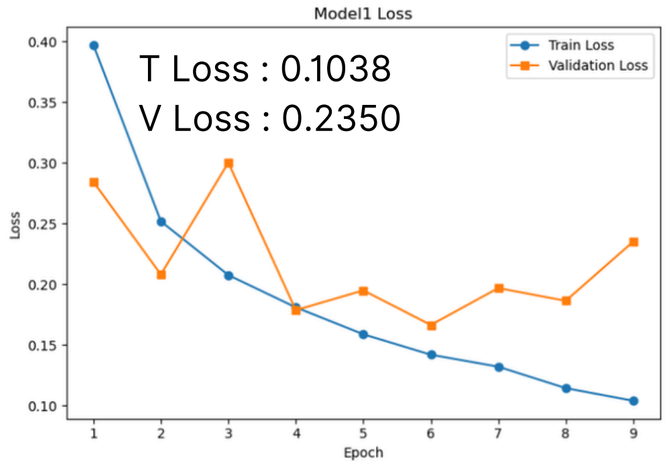
단계적 학습을 통한 일반화 성능 확보

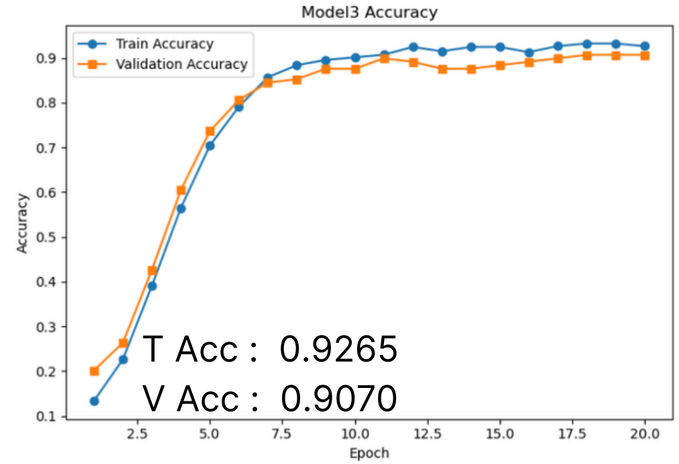
프로젝트 목표

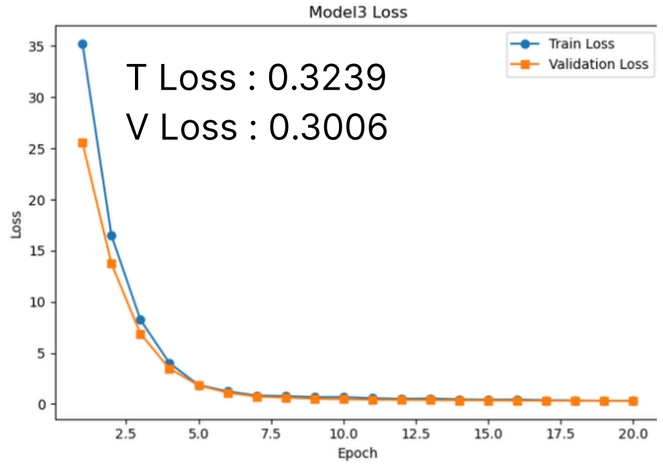
다양한 데이터셋을 순차적으로 학습하여

새로운 AI 이미지에도 강인한 탐지 모델 구축









Phase 1 | CIFAKE

↓

Phase 3 | AI vs Human Generated Dataset

단계적 학습을 통한 일반화 성능 확보

프로젝트 목표

다양한 데이터셋을 순차적으로 학습하여

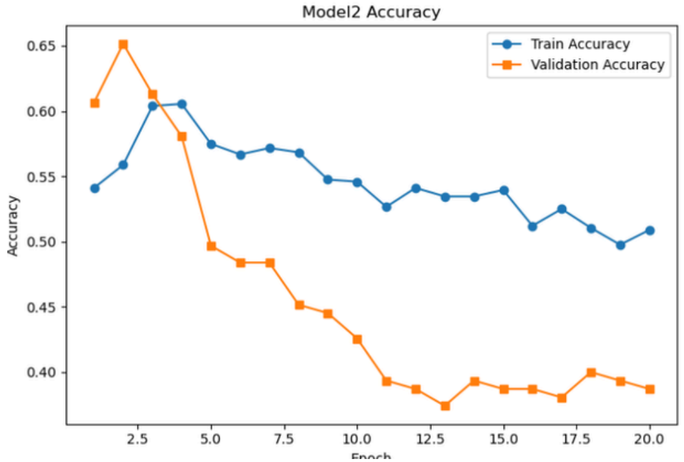
새로운 AI 이미지에도 강인한 탐지 모델 구축

Phase 1 | CIFAKE

↓

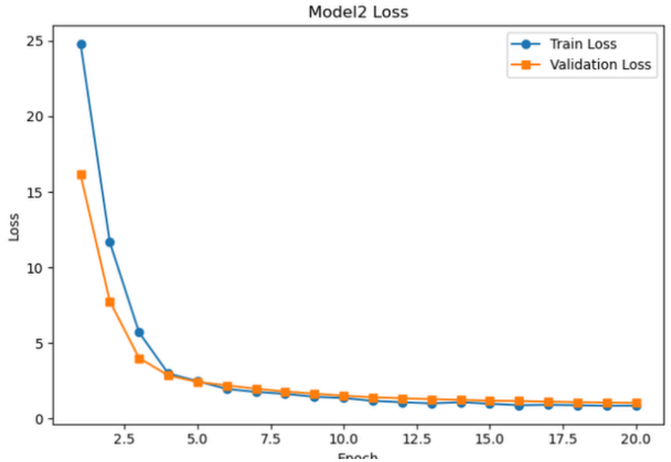
Phase 3 | AI vs Human Generated Dataset

Phase 2 : 학습 성능 저하로 제외



T Acc : 0.5089

V Acc : 0.3871



T Loss : 0.8622

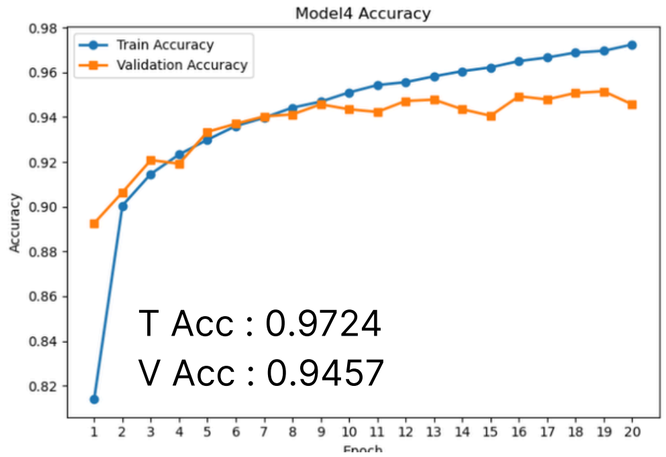
V Loss : 1.0523

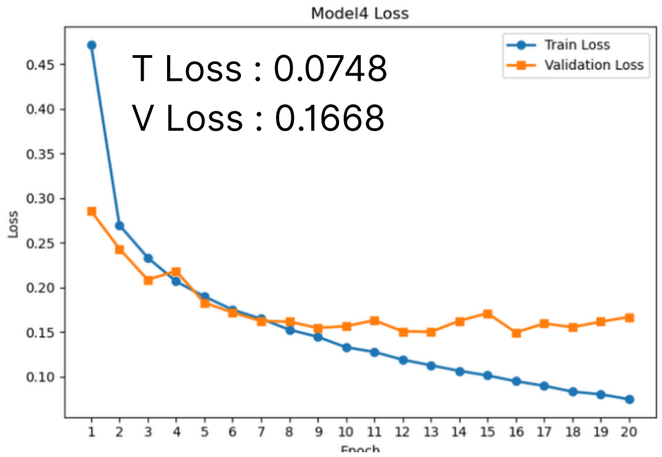
단계적 학습을 통한 일반화 성능 확보

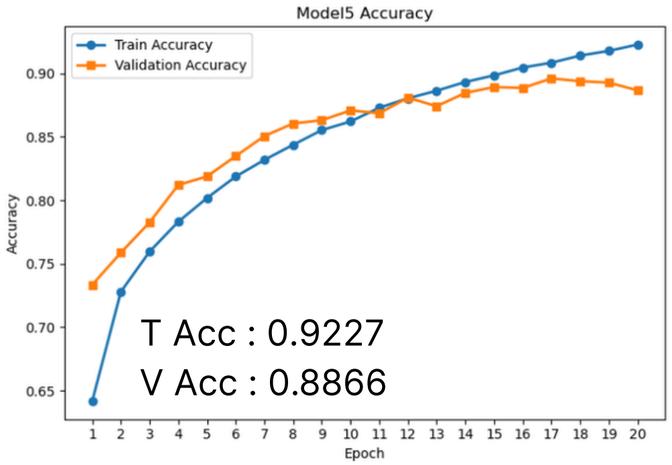
프로젝트 목표

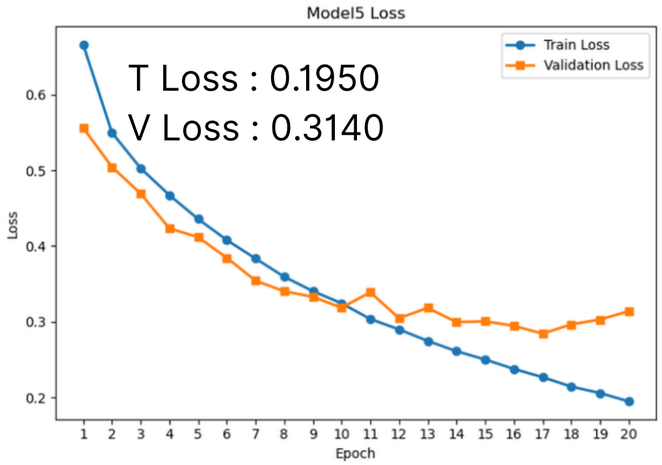
다양한 데이터셋을 순차적으로 학습하여

새로운 AI 이미지에도 강인한 탐지 모델 구축









Phase 1 | CIFAKE

↓

Phase 3 | AI vs Human Generated Dataset

↓

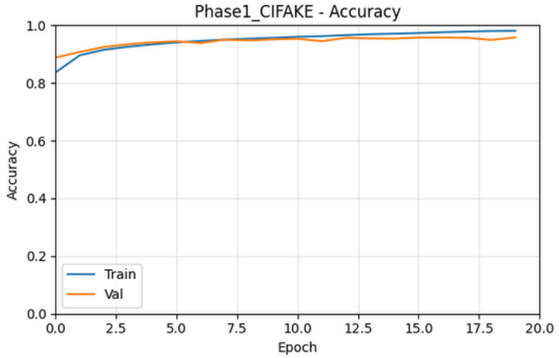
Phase 4 | AI vs Real Images Dataset

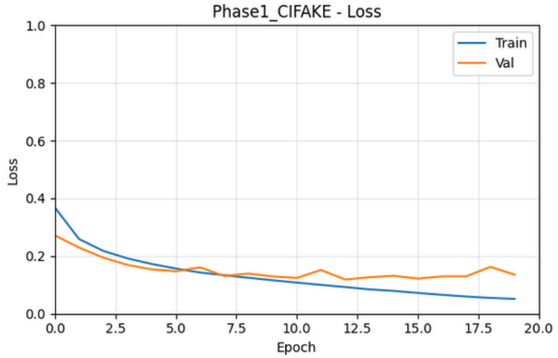
↓

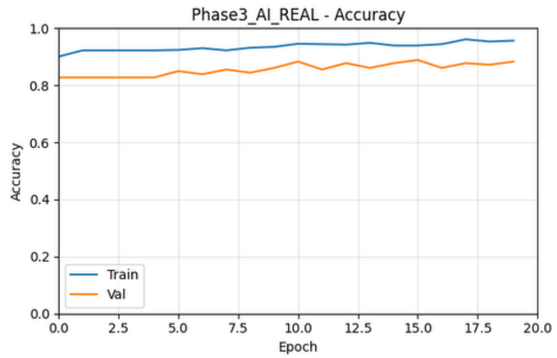
Phase 5 | Real vs AI Generated Faces Dataset

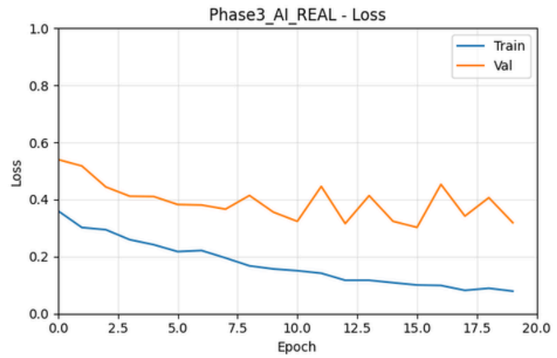
"단순 통합 학습이 아닌 단계적 학습 전략 적용"

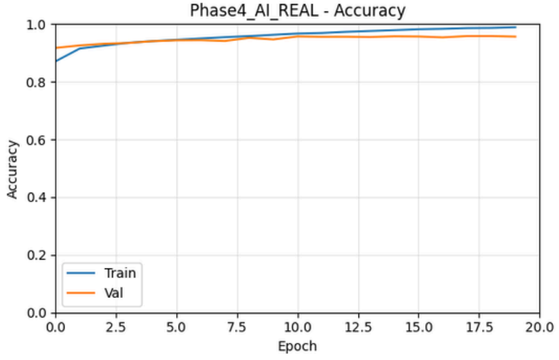
개별 학습 정확도 및 손실

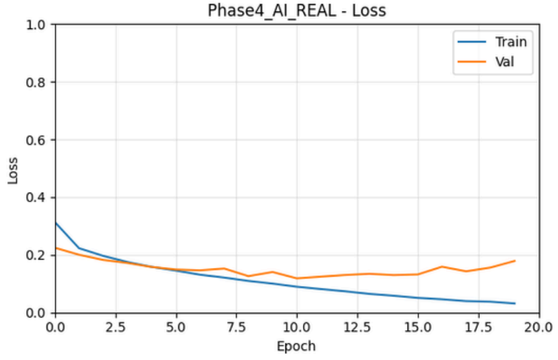

Phase1_CIFAKE - Accuracy
Accuracy
Epoch
Train
Val

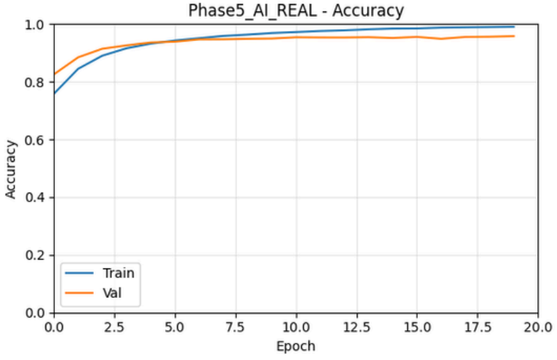

Phase1_CIFAKE - Loss
Loss
Epoch
Train
Val

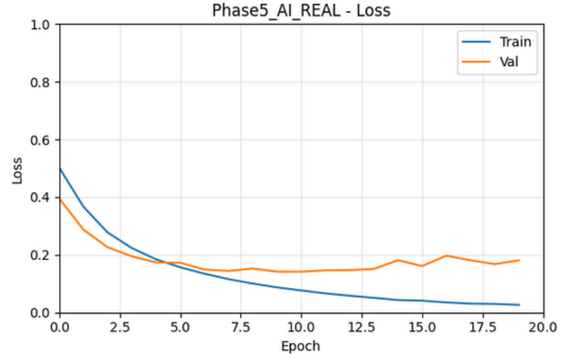

Phase3_AI_REAL - Accuracy
Accuracy
Epoch
Train
Val


Phase3_AI_REAL - Loss
Loss
Epoch
Train
Val

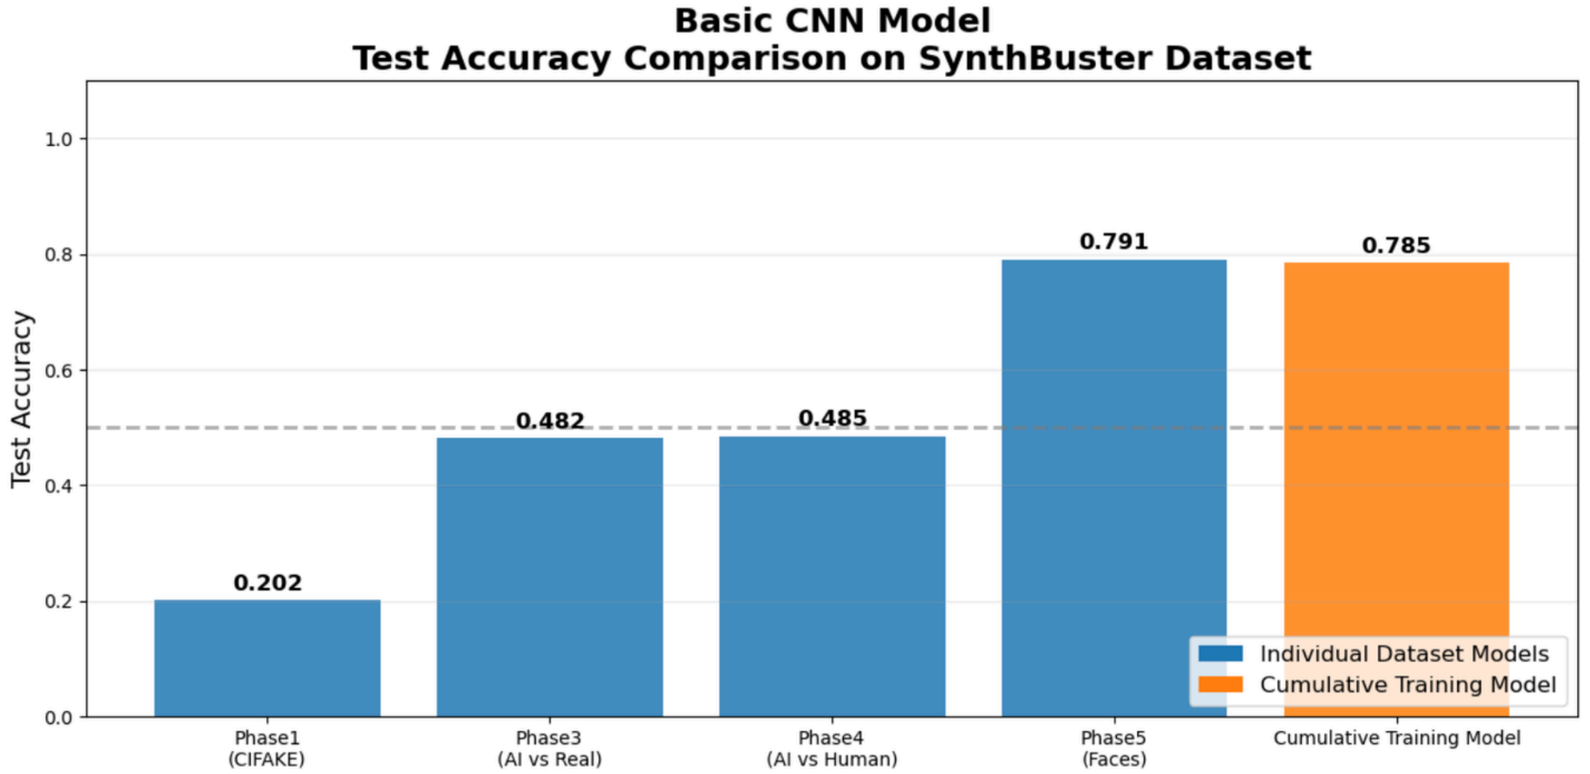

Phase4_AI_REAL - Accuracy
Accuracy
Epoch
Train
Val


Phase4_AI_REAL - Loss
Loss
Epoch
Train
Val


Phase5_AI_REAL - Accuracy
Accuracy
Epoch
Train
Val


Phase5_AI_REAL - Loss
Loss
Epoch
Train
Val

단계적 학습은 효과적인가?



"누적 학습 모델이 대부분의 개별 모델보다 높은 일반화 성능을 보였다."

설계(ResNet18)

비교 대상 ① 개별 학습 모델

Phase1 ResNet

Phase3 ResNet

Phase4 ResNet

Phase5 ResNet

각 데이터셋만 독립적으로 학습

VS

비교 대상 ② 누적 학습 모델

Phase1 → Phase3 → Phase4 → Phase5

이전 가중치를 유지한 채 순차적으로 학습

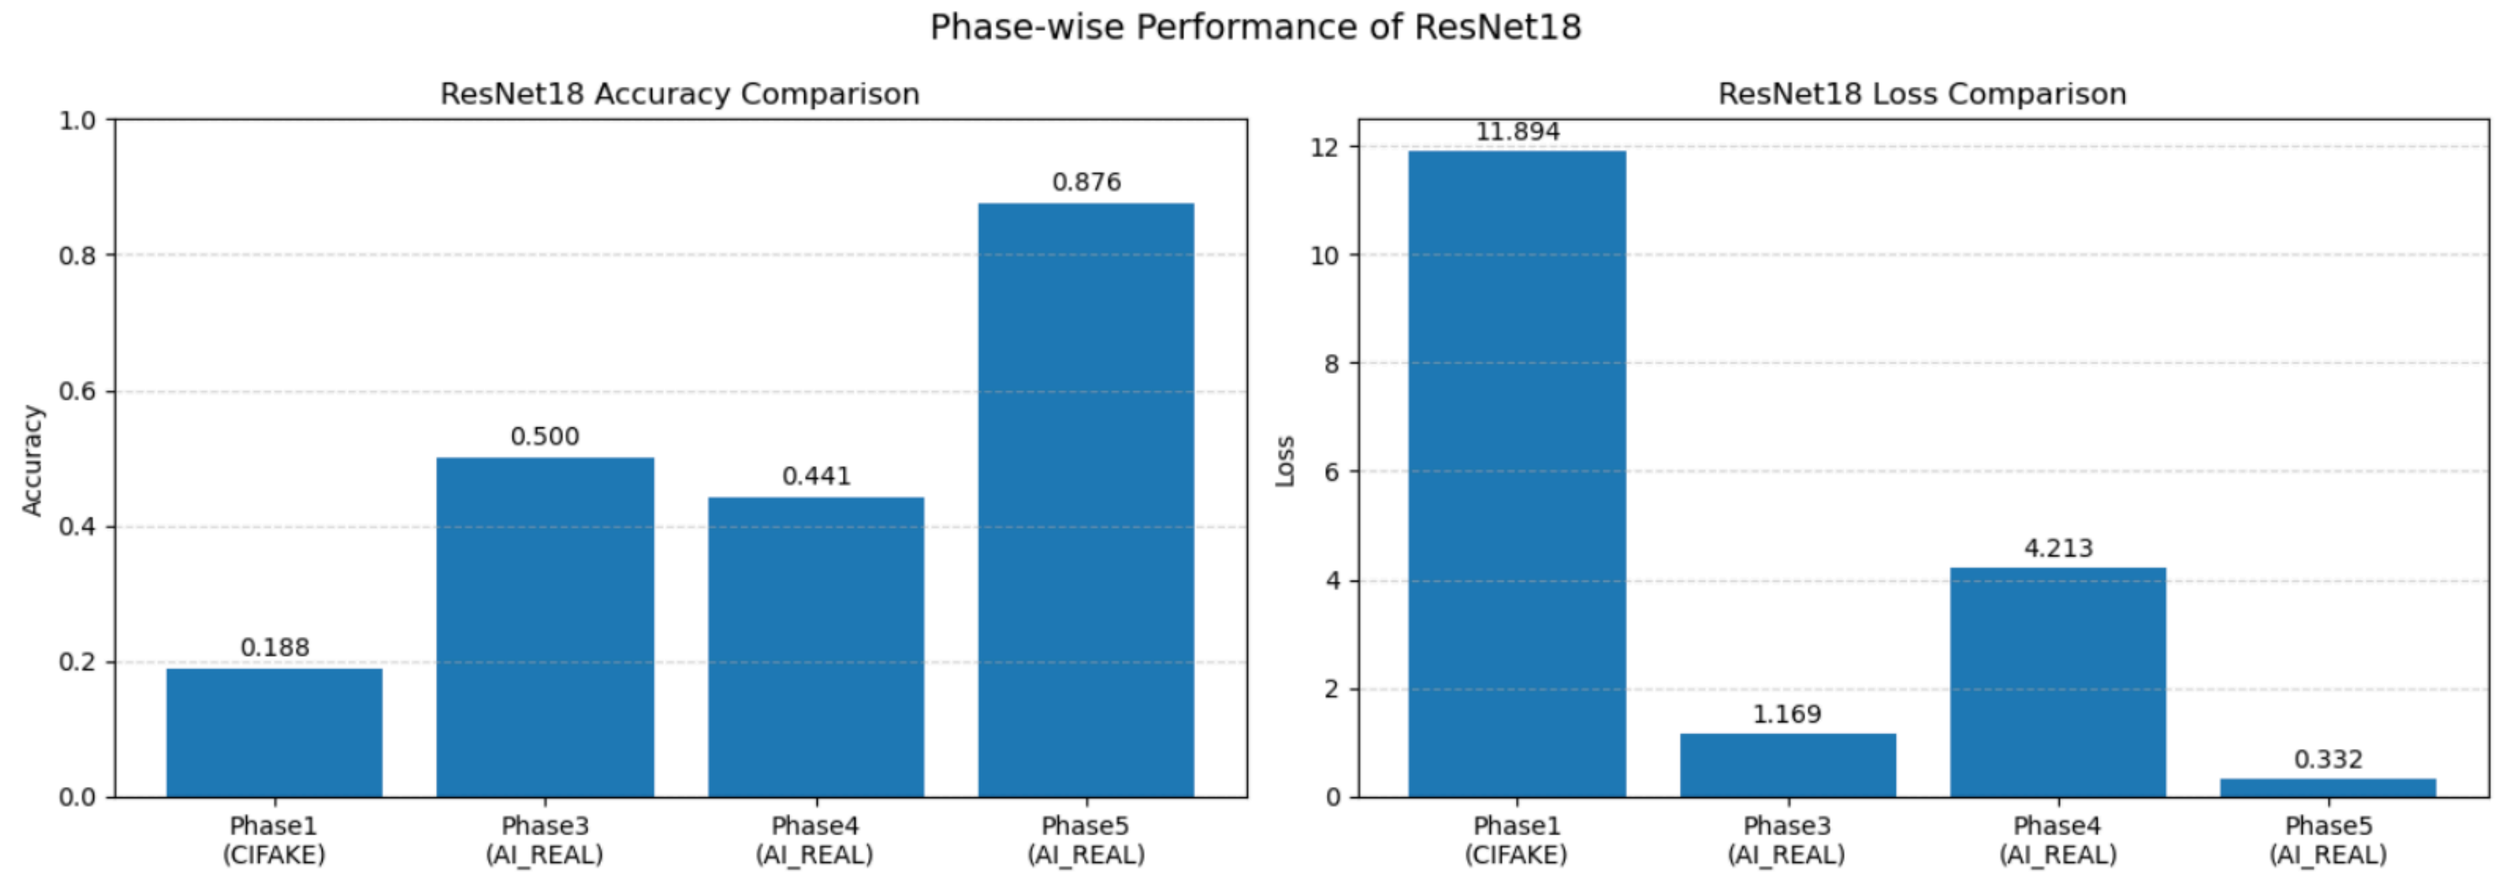
↓

Test DataSet : SynthBuster

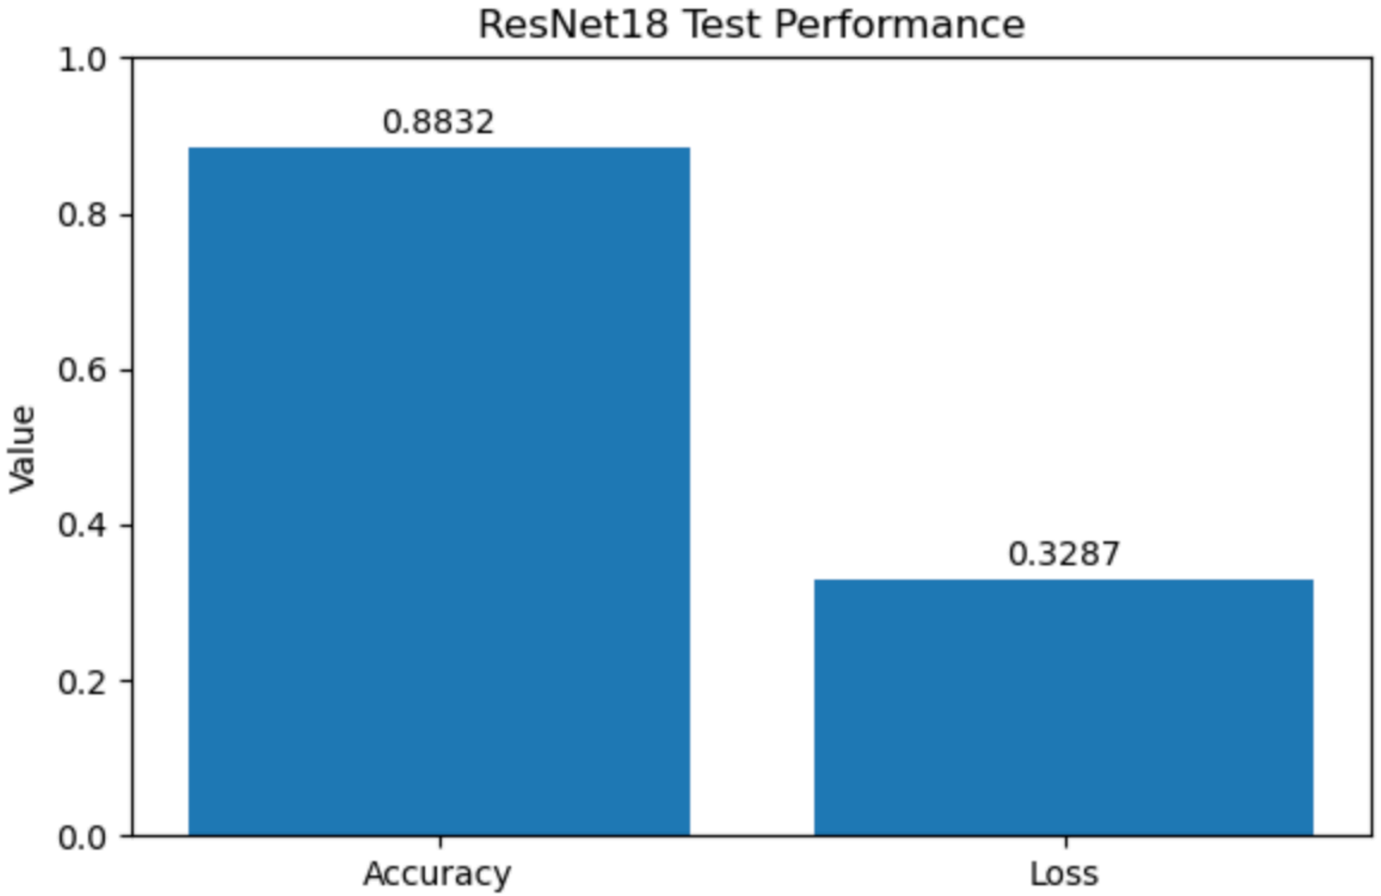
- 학습에 전혀 사용되지 않은 데이터
- 최신 AI 생성 이미지 포함
- 현실적인 일반화 성능 평가 가능
- 현재 가장 어려운 AI 이미지 탐지 벤치마크 중 하나

개별 ResNet 모델 VS 누적 ResNet 모델 → SynthBuster 평가

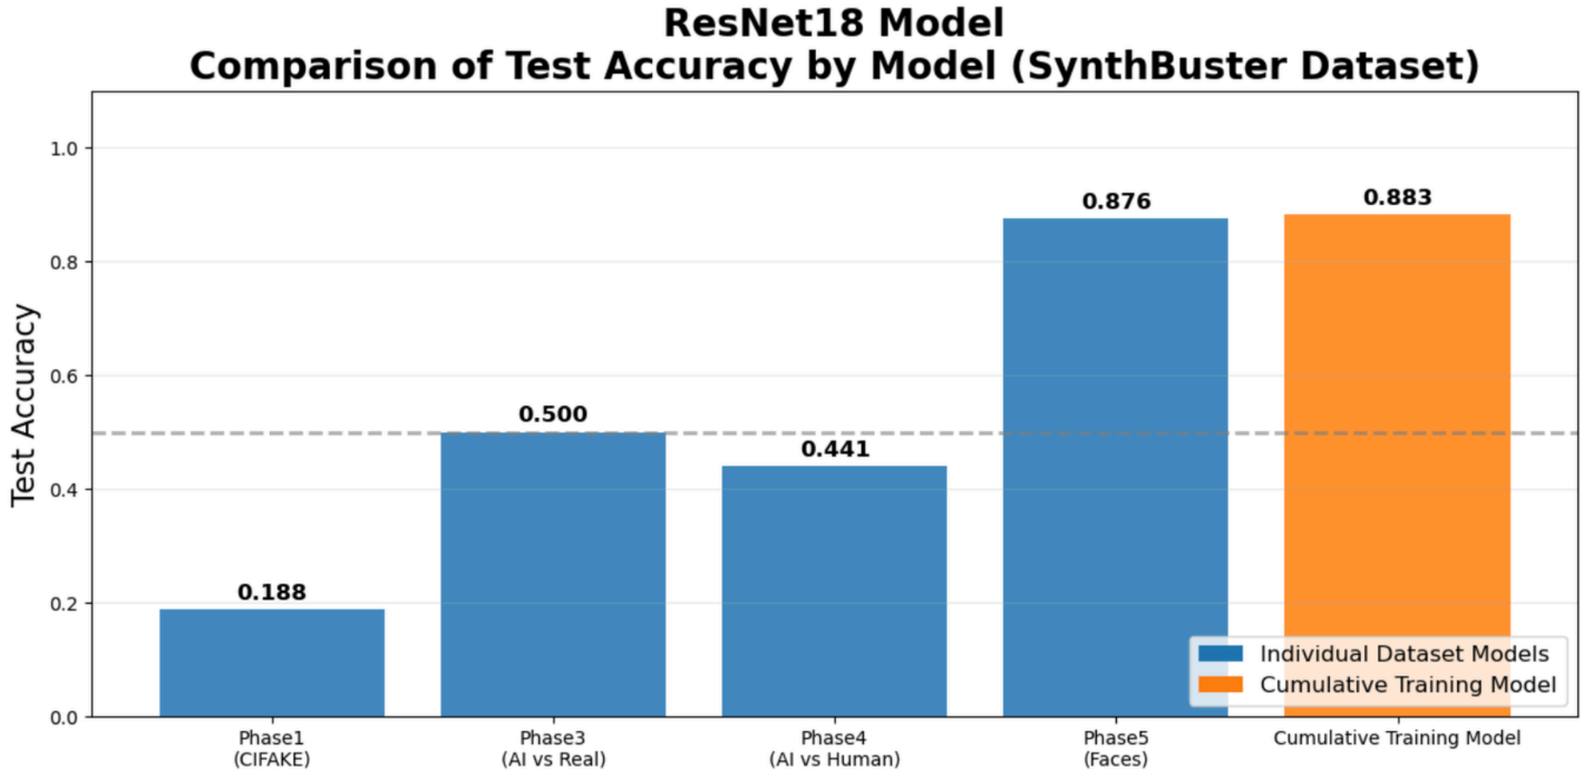
개별 학습 정확도 및 손실


Phase-wise Performance of ResNet18
ResNet18 Accuracy Comparison
Accuracy
1.0
0.8
0.6
0.4
0.2
0.0
0.188
0.500
0.441
0.876
Phase1 (CIFAKE)
Phase3 (AI_REAL)
Phase4 (AI_REAL)
Phase5 (AI_REAL)
ResNet18 Loss Comparison
Loss
12
10
8
6
4
2
0
11.894
1.169
4.213
0.332
Phase1 (CIFAKE)
Phase3 (AI_REAL)
Phase4 (AI_REAL)
Phase5 (AI_REAL)

누적 학습 정확도 및 손실

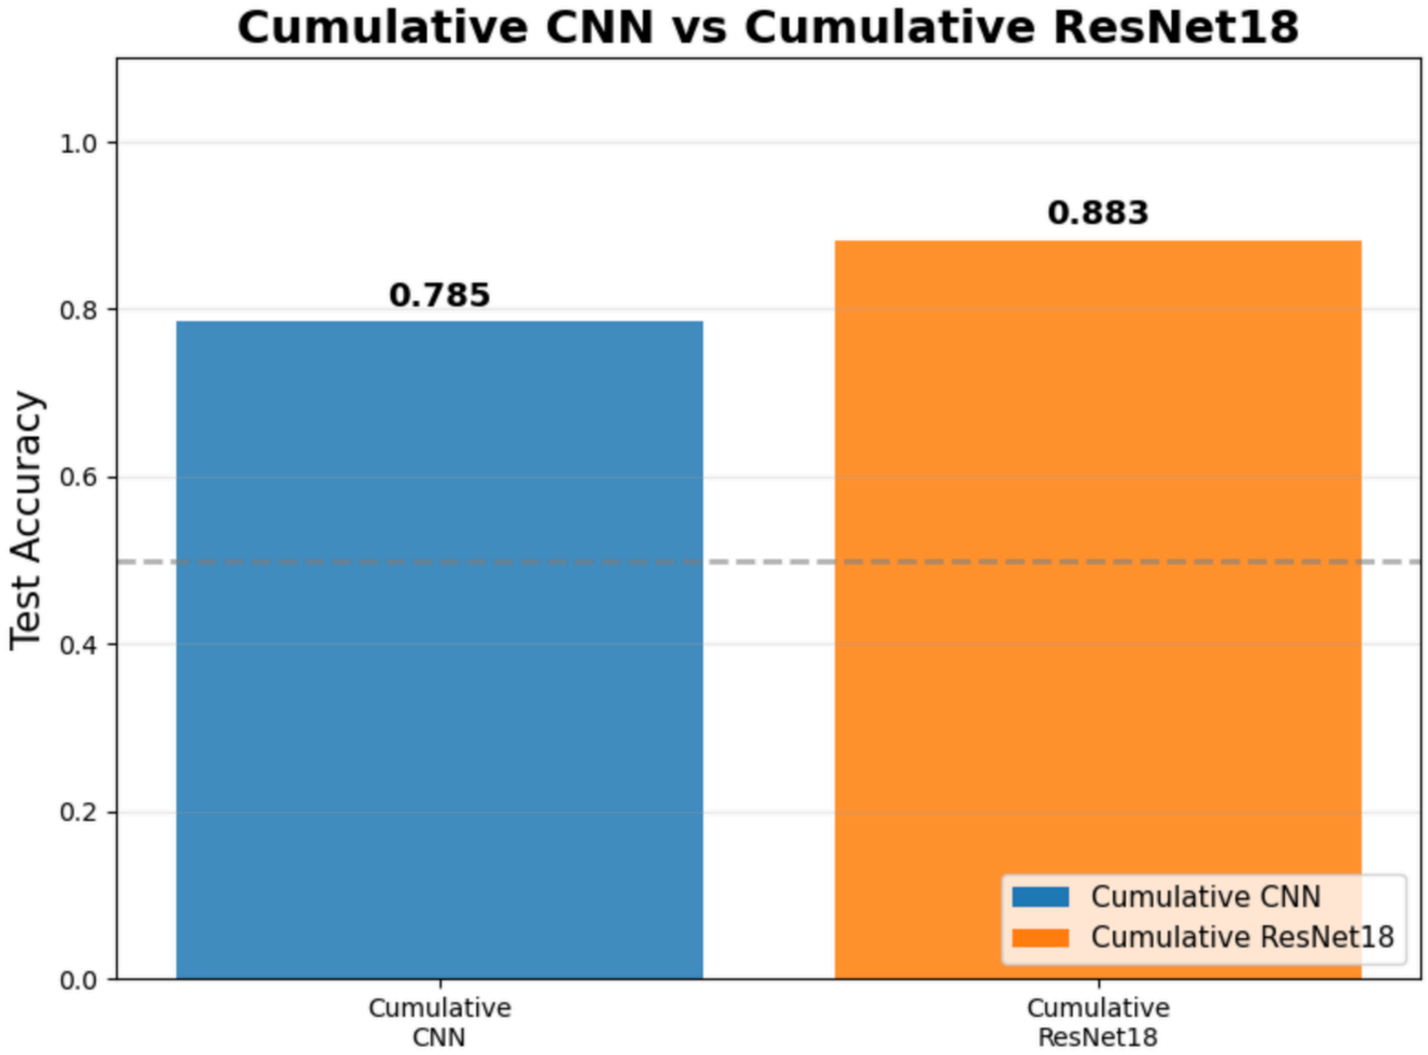

ResNet18 Test Performance
1.0
0.8
0.6
0.4
0.2
0.0
Value
0.8832
0.3287
Accuracy
Loss

단계적 학습은 효과적인가?



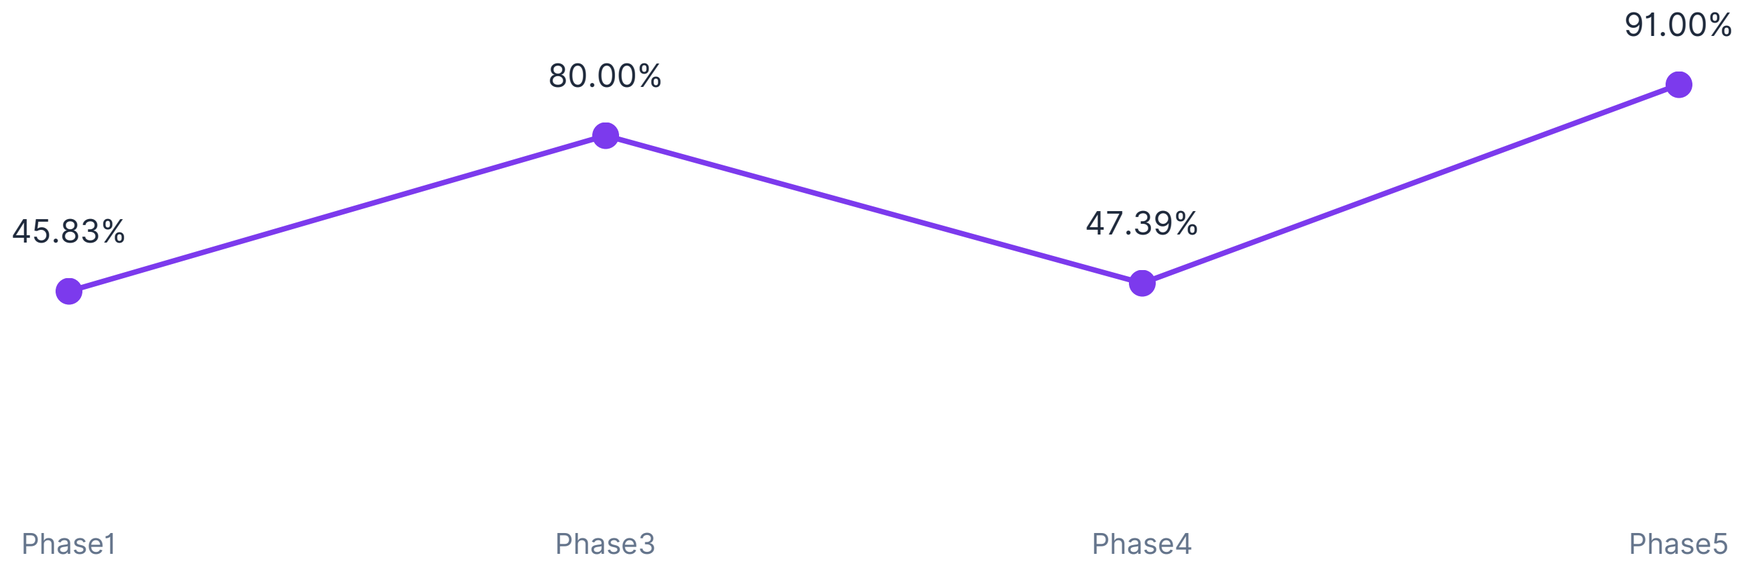
"누적 학습 모델이 대부분의 개별 모델보다 높은 일반화 성능을 보였다."

누적 학습 CNN vs ResNet 분석



CNN 누적 학습 내부 분석

정말 모든 데이터를 잘 기억하고 있을까?



Catastrophic Forgetting

새로운 데이터를 학습하면서 이전 지식을 잃어버리는 현상

"성능은 올라갔지만, 기억은 유지되지 않았다."

프로젝트를 통해 발견한 핵심 사실

01

단순히 데이터를 계속 추가한다고
일반화 성능이 보장되지는 않는다.

02

개별 모델은 특정 도메인에서는 우수하지만
새로운 데이터에 취약하다.

03

누적 학습은 일반화 성능 향상
가능성을 보여주었다.

04

그러나 Catastrophic Forgetting
문제가 발생하였다.

"진짜 문제는 데이터가 아니라 학습 전략이다."

결론 및 향후 연구

결론

- 단계적 학습의 가능성 확인
- 일반화 성능 향상 효과 관찰
- Catastrophic Forgetting 문제 발견

현재 한계

- Catastrophic Forgetting
- 데이터셋 간 도메인 차이

향후 계획

- 최신 AI 이미지 데이터셋을 활용한 일반화 성능 검증
- Replay Memory(장기 의존성 문제 보완)
- 수업 이외의 다양한 학습 기법 적용

단계적 학습을 시도했고,
그 과정에서 Catastrophic Forgetting이라는 실제 문제를 발견하였다.
이를 통해 단순 누적 학습보다 정교한 지속 학습 전략의 필요성을 확인하였다.

감사합니다

Q&A